

Generative Adversarial Networks

Davi Barreira

FGV - Escola de Matemática Aplicada

Table of contents

1. Introdução
2. Formalização Teórica

Generative Adversarial Networks (GAN) foram originalmente introduzidas por Goodfellow et al. (2014). Essas redes são utilizadas com o objetivo de gerar dados sintéticos realísticos a partir de dados reais.



Figure 1: Faces geradas por GAN ¹.

¹<https://towardsdatascience.com/generating-modern-arts-using-generative-adversarial-network-gan-on-spell-39f67f83c7b4>

Introdução

A geração de novas amostras sintéticas tem diferentes utilidades, como aprendizado semi-supervisionado, geração de exemplos adversariais, *style transfer*, entre outros.



Figure 2: Style transfer utilizando CycleGan ².

²<https://towardsdatascience.com/style-transfer-with-gans-on-hd-images-88e8efcf3716>

Introdução

A ideia geral por trás das GANs é utilizar duas redes neurais competindo uma com a outra, sendo uma rede responsável por gerar amostras parecidas com os dados reais, enquanto a outra busca identificar quando o dado é real ou sintético.

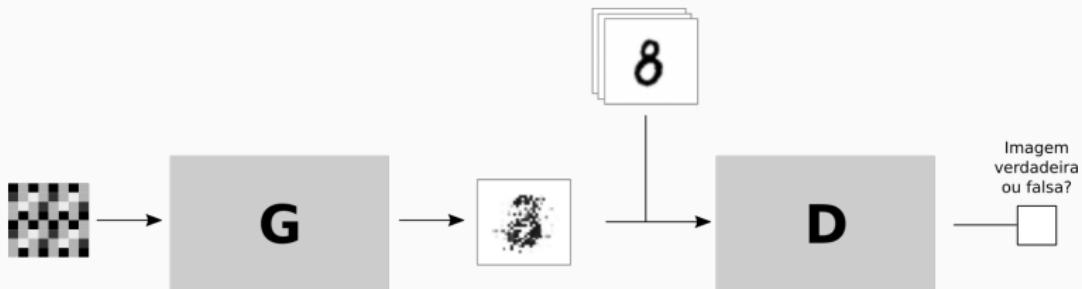


Figure 3: Desenho esquemático de uma GAN "convencional".

Entendendo a Função Objetivo

$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(z)} [1 - \log(D(G(z)))]$$

Entendendo a Função Objetivo

$$\begin{aligned} V(D, G) &= \mathbb{E}_{x \sim p_{data}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(z)} [1 - \log(D(G(z)))] \\ &= \int_x p_{data}(x) \log(D(x)) dx + \int_z p_z(z) \log(1 - D(G(z))) dz \end{aligned}$$

Entendendo a Função Objetivo

$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(z)} [1 - \log(D(G(z)))]$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_z p_z(z) \log(1 - D(G(z))) dz$$

$$x = G(z) \rightarrow z = G^{-1}(x) \rightarrow dz = (G^{-1}(x))dx$$

$$\rightarrow p_g(x) = p_z(G^{-1})(G^{-1})'(x)dx$$

Entendendo a Função Objetivo

$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(z)} [1 - \log(D(G(z)))]$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_z p_z(z) \log(1 - D(G(z))) dz$$

$$x = G(z) \rightarrow z = G^{-1}(x) \rightarrow dz = (G^{-1}(x))dx$$

$$\rightarrow p_g(x) = p_z(G^{-1})(G^{-1})'(x)dx$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_x p_z(G^{-1}(x)) \log(1 - D(x))(G^{-1})'(x) dx$$

Entendendo a Função Objetivo

$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(z)} [1 - \log(D(G(z)))]$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_z p_z(z) \log(1 - D(G(z))) dz$$

$$x = G(z) \rightarrow z = G^{-1}(x) \rightarrow dz = (G^{-1}(x))dx$$

$$\rightarrow p_g(x) = p_z(G^{-1})(G^{-1})'(x)dx$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_x p_z(G^{-1}(x)) \log(1 - D(x))(G^{-1})'(x) dx$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_x p_g(x) \log(1 - D(x)) dx$$

Entendendo a Função Objetivo

$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(z)} [1 - \log(D(G(z)))]$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_z p_z(z) \log(1 - D(G(z))) dz$$

$$x = G(z) \rightarrow z = G^{-1}(x) \rightarrow dz = (G^{-1}(x))dx$$

$$\rightarrow p_g(x) = p_z(G^{-1})(G^{-1})'(x)dx$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_x p_z(G^{-1}(x)) \log(1 - D(x))(G^{-1})'(x) dx$$

$$= \int_x p_{data}(x) \log(D(x)) dx + \int_x p_g(x) \log(1 - D(x)) dx$$

$$= \int_x p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x)) dx$$

Entendendo a Função Objetivo

$$\max_D V(D, G) = \max_D \int_x p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x)) dx$$

Entendendo a Função Objetivo

$$\max_D V(D, G) = \max_D \int_x p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x)) dx$$

$$\frac{\partial}{\partial D(x)} (p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x))) = 0$$

Entendendo a Função Objetivo

$$\max_D V(D, G) = \max_D \int_x p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x)) dx$$

$$\frac{\partial}{\partial D(x)} (p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x))) = 0$$

$$\rightarrow \frac{p_{data}(x)}{D(x)} - \frac{p_g(x)}{1 - D(x)} = 0$$

$$\rightarrow D(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

Entendendo a Função Objetivo

Suponha que o discriminador $D_G^*(x)$ seja ótimo
Então o gerador ótimo produz $p_g(x) = p_{data}(x)$

$$\rightarrow D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

Entendendo a Função Objetivo

$$C(G) = \max_D V(G, D)$$

Entendendo a Função Objetivo

$$\begin{aligned} C(G) &= \max_D V(G, D) \\ &= \max_D \int_x p_{data}(x) \log D(x) + p_g \log 1 - D(x) dx \end{aligned}$$

Entendendo a Função Objetivo

$$\begin{aligned} C(G) &= \max_D V(G, D) \\ &= \max_D \int_x p_{data}(x) \log D(x) + p_g \log 1 - D(x) dx \\ &= \int_x p_{data}(x) \log (D_G^*(x)) + p_g(x) \log (1 - D_g^*(x)) dx \end{aligned}$$

Entendendo a Função Objetivo

$$\begin{aligned} C(G) &= \max_D V(G, D) \\ &= \max_D \int_x p_{data}(x) \log D(x) + p_g \log 1 - D(x) dx \\ &= \int_x p_{data}(x) \log (D_G^*(x)) + p_g(x) \log (1 - D_g^*(x)) dx \\ &= \int_x p_{data}(x) \log \left(\frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right) + p_g(x) \log \left(\frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right) dx \end{aligned}$$

Entendendo a Função Objetivo

$$\begin{aligned} C(G) &= \max_D V(G, D) \\ &= \max_D \int_x p_{data}(x) \log D(x) + p_g \log 1 - D(x) dx \\ &= \int_x p_{data}(x) \log (D_G^*(x)) + p_g(x) \log (1 - D_g^*(x)) dx \\ &= \int_x p_{data}(x) \log \left(\frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right) + p_g(x) \log \left(\frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right) dx \\ &= \int_x p_{data}(x) \log \left(\frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} \right) + p_g(x) \log \left(\frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} \right) dx \end{aligned}$$

Entendendo a Função Objetivo

$$\begin{aligned} C(G) &= \max_D V(G, D) \\ &= \max_D \int_x p_{data}(x) \log D(x) + p_g \log 1 - D(x) dx \\ &= \int_x p_{data}(x) \log (D_G^*(x)) + p_g(x) \log (1 - D_g^*(x)) dx \\ &= \int_x p_{data}(x) \log \left(\frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right) + p_g(x) \log \left(\frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right) dx \\ &= \int_x p_{data}(x) \log \left(\frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} \right) + p_g(x) \log \left(\frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} \right) dx \\ &= KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] + KL \left[p_g(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] - \log 4 \end{aligned}$$

Entendendo a Função Objetivo

$$C(G) = KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] + KL \left[p_g(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] - \log 4$$

Entendendo a Função Objetivo

$$C(G) = KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] + KL \left[p_g(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] - \log 4$$

$$\min_G C(G) = 0 + 0 - \log 4 = -\log 4$$

$$KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] = 0$$

Entendendo a Função Objetivo

$$C(G) = KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] + KL \left[p_g(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] - \log 4$$

$$\min_G C(G) = 0 + 0 - \log 4 = -\log 4$$

$$KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] = 0$$

$$\text{quando, } p_{data}(x) = \frac{p_{data}(x) + p_g(x)}{2}$$

Entendendo a Função Objetivo

$$C(G) = KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] + KL \left[p_g(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] - \log 4$$

$$\min_G C(G) = 0 + 0 - \log 4 = -\log 4$$

$$KL \left[p_{data}(x) \middle\| \frac{p_{data}(x) + p_g(x)}{2} \right] = 0$$

$$\text{quando, } p_{data}(x) = \frac{p_{data}(x) + p_g(x)}{2}$$

$$\rightarrow p_{data}(x) = p_g(x)$$

KL (Kullback-Leibler) divergence

Jensen-Shannon Divergency (symetric KL):

$$JSD(P||Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M),$$

$$M = \frac{1}{2}(P + Q)$$

Resumo:

$$V(G, D) = \mathbb{E}_{x \sim p_{data}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(x)} [1 - \log(D(D(z)))]$$

Gerador G , Discriminador D

Encontro G^* , tal que

$$G^* = \arg \min_G \max_D V(G, D)$$

Dado G , $\max_D V(G, D)$

$$= -2 \log 2 + 2JSD(P_{data}(x) || P_g(x))$$

Formalização Teórica

Algorithm 1: GAN descrita em Goodfellow et al. (2014)

for número de iterações de treino **do**

for k passos **do**

 Amostre m valores $\{z^{(1)}, \dots, z^{(m)}\}$ da priori $p_z(z)$;

 Amostre m exemplos $\{x^{(1)}, \dots, x^{(m)}\}$ da função dos dados $p_{data}(x)$;

 Atualize o *discriminator* utilizando *stochastic gradient descent*:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log(1 - D(G(z^{(i)}))) \right]$$

end

 Amostre m valores $\{z^{(1)}, \dots, z^{(m)}\}$ da priori $p_z(z)$;

 Atualize o *generator* utilizando *stochastic gradient descent*:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(z^{(i)})))$$

end

References i

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. (2014). Generative adversarial nets. In Ghahramani, Z., Welling, M., Cortes, C., Lawrence, N. D., and Weinberger, K. Q., editors, *Advances in Neural Information Processing Systems 27*, pages 2672–2680. Curran Associates, Inc.